

Proyecto



Pontificia Universidad Javeriana

Procesamiento de datos

Ian Tomás Felipe Fonseca Coronado.

Andres Raba.

Jorge Esteban Gomez Zuluaga.

Daniel Galvis.

Bogotá D.C.

25 de abril de 2026

1. Entendimiento del negocio:

- **Objetivo general:** Identificar la relación entre la cobertura y la calidad del acceso a internet con los resultados de las pruebas ICFES 11 en 3 municipios del departamento de Antioquia.
- **Objetivo específico 1:** Determinar la calidad de cobertura y del servicio de internet en los municipios del departamento de Antioquia.
- **Objetivo específico 2:** Correlacionar el acceso a internet con los resultados de las pruebas ICFES en los municipios de Antioquia.
- **Objetivo específico 3:** Categorizar los municipios con mejores y peores resultados en las pruebas ICFES 11 en Antioquia.
- **Objetivo específico 4:** Establecer los municipios con mayores necesidades de intervención a partir del análisis del acceso a internet y los resultados en las pruebas ICFES.

2. Selección de los datos a utilizar:

Las bases de datos que van a ser usadas para nuestro proyecto son las siguientes:

- **Cuadros_salida_saber_11_2023** : una base de datos por parte del propio ICFES que contiene datos acumulados desde el 2021 hasta el 2023 de los resultados de las pruebas icfes, separados en formatos diferente.
- **Internet_Fijo_Accesos_por_tecnología_y_segmento_2021**: Una parte de una base de datos que contiene los datos de servicio fijo de internet dividido en municipios, del año 2021.
- **Internet_Fijo_Accesos_por_tecnología_y_segmento_2022_a_2023**: Una parte de una base de datos que contiene los datos de servicio fijo de internet dividido en municipios, del año 2022 y 2023.

3. Colección y descripción de datos:

Los tres conjuntos de datos fueron cargados en el clúster Apache Spark mediante PySpark. A continuación se describe cada dataset.

3.1 Tipos de datos

[INSERTAR AQUÍ: Salida de printSchema() de los tres datasets desde el clúster Spark]

3.2 Comprensión del significado de cada atributo

A continuación se describe el significado de los atributos más relevantes de cada dataset:

Dataset: CUADROS_SALIDA_SABER_11_2023

- **ESTU_MUNICIPIO_PRESENTACION:** Municipio donde el estudiante presentó las pruebas Saber 11.
- **COLE_SECTOR:** Sector al que pertenece el colegio: OFICIAL o NO OFICIAL (privado).
- **PUNT_MATEMATICAS:** Puntaje obtenido en el área de Matemáticas. Escala de 0 a 100.
- **PUNT_LECTURA_CRITICA:** Puntaje obtenido en Lectura Crítica. Escala de 0 a 100.
- **PUNT_CIENCIAS_NATURALES:** Puntaje obtenido en Ciencias Naturales. Escala de 0 a 100.
- **PUNT_SOCIALES_CIUDADANAS:** Puntaje obtenido en Ciencias Sociales y Ciudadanas. Escala de 0 a 100.
- **PUNT_INGLES:** Puntaje obtenido en Inglés. Escala de 0 a 100.
- **PUNT_GLOBAL:** Puntaje global del estudiante, calculado como agregado de las áreas evaluadas.
- **PERIODO:** Año y periodo de presentación del examen (ej. 20231 = primer semestre de 2023).

Datasets: INTERNET_FIJO_ACCESOS_POR_TECNOLOGÍA_Y_SEGMENTO (2021 y 2022–2023)

- **DEPARTAMENTO:** Departamento al que pertenece el municipio registrado.
- **MUNICIPIO:** Nombre del municipio con accesos de internet fijo reportados.
- **TECNOLOGÍA:** Tipo de tecnología de acceso: Fibra óptica (FTTH), Cable coaxial híbrido (HFC), XDSL, Inalámbrica fija, Satélite, WiMAX, entre otras.
- **SEGMENTO:** Tipo de usuario del servicio: residencial, corporativo o gobierno.
- **NO DE ACCESOS:** Número de conexiones de internet fijo activas reportadas para ese municipio, tecnología y segmento.
- **AÑO / TRIMESTRE:** Período de reporte de los datos (disponible en el dataset 2022–2023).

3.3 Descripción general del contenido de los conjuntos de datos

- El dataset de Saber 11 concentra la información académica de los estudiantes que presentaron el examen entre 2021 y 2023. Tras aplicar el filtro por municipio, contiene únicamente registros de Bello, Itagüí y Envigado, permitiendo comparaciones entre sectores educativos, áreas de conocimiento y periodos anuales.
- Los datasets de internet fijo (2021 y 2022–2023) provienen del Ministerio de TIC de Colombia y registran el número de accesos de banda ancha fija por municipio, tecnología y segmento. Esto permite medir no solo la cantidad sino el tipo de conectividad disponible en cada municipio.

- Al integrar los tres datasets es posible construir un perfil de cada municipio que combina su nivel de conectividad fija con su desempeño académico en las pruebas Saber 11, permitiendo explorar si existe una relación estadísticamente significativa entre ambas variables.

[INSERTAR AQUÍ: Salida de show() o describe() de cada dataset desde el clúster Spark]

4. Exploración de los datos:


A continuación se presentan los ocho elementos de análisis exploratorio realizados sobre los conjuntos de datos filtrados para los municipios de Bello, Itagüí y Envigado.

4.1 Estadísticos descriptivos de Accesos a Internet

	summary	No DE ACCESOS
0	count	213245
1	mean	52.84926727473094
2	stddev	421.6692784167676
3	min	0
4	max	32439

- Los estadísticos descriptivos del campo Número de Accesos reflejan una distribución altamente asimétrica: la media se ubica alrededor de 52,8 accesos por registro mientras la desviación estándar supera los 421, con valores que oscilan entre 0 y 32.439. Esta dispersión indica concentración del servicio en tecnologías específicas. El valor mínimo de 0 corresponde a tecnologías habilitadas sin accesos activos, lo cual también es relevante para el análisis.

4.2 Accesos por Tecnología en Antioquia (2022–2023)



- La distribución por tecnología muestra que la fibra óptica hasta el hogar (FTTH) es ampliamente dominante, seguida por el cable coaxial híbrido (HFC). El resto de tecnologías tienen participación marginal. Este patrón es consistente con la transición hacia redes de nueva generación ocurrida en Colombia durante 2021–2023, más visible en municipios con alta densidad urbana como los seleccionados.

4.3 Comparativa de Accesos Totales 2021 vs. 2022–2023


3. Comparativa de Accesos en Antioquia:

2021: 5,878,310

2022-2023: 11,269,842


- La comparación entre el total de accesos en 2021 (5.878.310 en Antioquia) y el período 2022–2023 (11.269.842) evidencia un crecimiento cercano al 92 %. Para los municipios de Bello, Itagüí y Envigado este crecimiento es proporcional y refleja la expansión de la infraestructura de fibra óptica. Este incremento coincide con los últimos periodos de evaluación Saber 11 disponibles, lo que resulta favorable para el cruce de variables.

4.4 Top 10 Municipios de Antioquia por Conectividad




- Al ordenar los municipios por número total de accesos (excluido Medellín), Bello, Itagüí y Envigado ocupan los tres primeros lugares. Esta posición se debe a su alta densidad poblacional y mayor presencia de operadores. La diferencia respecto a municipios como Rionegro o Sabaneta es considerable, lo que refuerza su elección como unidades de análisis representativas del departamento.

4.5 Promedio de Puntajes Saber 11 por Sector Educativo




- El análisis por sector educativo revela una brecha consistente: las instituciones no oficiales (privadas) superan a las oficiales en todas las áreas. Los puntajes del sector no oficial se ubican entre 60 y 70 puntos, mientras el sector oficial promedia entre 45 y 52. Esta diferencia puede responder a nivel socioeconómico de los estudiantes, disponibilidad de recursos y conectividad en el hogar, entre otros factores.

4.6 Matriz de Correlación entre Áreas Académicas




- La matriz de correlación entre los puntajes de las cinco áreas evaluadas muestra valores en el rango 0,96–0,99. Esto indica que los resultados de las distintas materias se comportan de manera casi idéntica: quien obtiene buenos resultados en una área tiende a obtenerlos en las demás. Esta multicolinealidad deberá tenerse en cuenta en la fase de modelado, posiblemente requiriendo eliminación de variables o reducción de dimensionalidad.

4.7 Puntaje Total vs. Conectividad por Sector Educativo



- La gráfica de dispersión entre la intensidad de conectividad (Log10 de accesos) y el puntaje total promedio sugiere una tendencia positiva en el sector no oficial: a mayor conectividad, mayor puntaje. En el sector oficial la tendencia también es positiva pero con mayor variabilidad, indicando que la conectividad por sí sola no explica completamente el desempeño en colegios públicos.

4.8 Brecha de Rendimiento: Sector Oficial vs. No Oficial



- El boxplot permite visualizar no solo los promedios sino la dispersión de los datos. El sector no oficial presenta una distribución concentrada con la mediana alrededor de 60 puntos. El sector oficial muestra mayor heterogeneidad con mediana cercana a 48 puntos. Los valores atípicos inferiores en el sector oficial identifican instituciones con desempeño particularmente bajo, las cuales deberían ser objeto prioritario de las políticas de intervención.

5. Reporte de calidad de datos:

5.1 Identificación de Valores faltantes

Al momento de recolectar los datos se identificó valores faltantes:

- **Internet Fijo (2021 y 2022-2023):** No se detectaron valores faltantes en ninguna de las variables. Esto indica que los datos están completos y listos para ser utilizados directamente en las fases de análisis.
- **Pruebas Saber 11 (2023):** Se identificó la presencia de diversas columnas con un alto porcentaje de datos vacíos, principalmente aquellas que el sistema importó bajo el nombre de "Unnamed"

5.2 Análisis de calidad de datos

A partir del análisis de los data set se pudo concluir:

- **Bases de datos de Internet:** Presentan un nivel óptimo de calidad, destacando por su estructura adecuada y la ausencia total de datos faltantes.
- **Base de datos de Saber 11:** La incidencia de valores nulos se concentra exclusivamente en columnas que no aportan información relevante para el estudio, lo que sugiere que son producto de errores en la estructura o durante la exportación del archivo original. Es importante destacar que no se encontraron valores faltantes significativos dentro de las variables principales requeridas para el análisis.

5.3 Tratamiento de valores faltantes

Con el objetivo de garantizar la integridad y confiabilidad de los datos, se implementarán las siguientes estrategias:

Eliminación de columnas irrelevantes: Se procederá a suprimir las columnas denominadas "Unnamed", ya que carecen de utilidad analítica y concentran una gran cantidad de valores vacíos.

Validación de variables clave: Se revisarán minuciosamente las variables fundamentales (como municipio, puntajes y acceso a internet) para asegurar que no contengan registros vacíos o incompletos que puedan alterar el análisis.

Protocolo ante posibles valores faltantes futuros: En caso de detectar valores nulos en variables relevantes durante etapas posteriores, se aplicarán las siguientes técnicas de manejo de datos:

Para variables numéricas: Uso de la media o la mediana.

Para variables categóricas: Uso de la moda.

Eliminación directa de registros: Exclusivamente si la cantidad de datos faltantes es muy baja y no compromete la muestra.

6. Preguntas sobre los datos:

- ¿Cuál es el nivel de cobertura del servicio de internet fijo en los municipios del departamento de Antioquia durante el periodo 2021–2023?
- ¿Los municipios con mejor calidad de conectividad presentan mejores resultados en las pruebas ICFES 11?
- ¿Cuáles son los municipios de Antioquia con los mejores resultados en las pruebas Saber 11 ?
- ¿Qué municipios de Antioquia deberían ser priorizados en futuras estrategias de mejoramiento de conectividad?
- ¿Qué patrones observados entre 2021 y 2023 permiten estimar tendencias futuras sobre la relación entre conectividad y desempeño académico en los municipios de Antioquia?
- ¿Es posible proyectar qué municipios podrían mejorar su desempeño en las pruebas Saber 11 a partir de un aumento en el acceso o calidad del servicio de internet fijo?
- ¿Qué municipios presentan buenos resultados en Saber 11 con baja conectividad o malos resultados con alta conectividad?
- ¿Es posible agrupar o categorizar los municipios de Antioquia según niveles de conectividad y desempeño académico para identificar relaciones?

7. Filtros, limpieza y transformación inicial:

En este apartado se describen los filtros, procesos de limpieza y transformaciones iniciales aplicados sobre los datos. El proceso completo será presentado en la segunda entrega.

7.1 Filtros aplicados

- **Filtro 1 – Selección por municipio:** Se filtraron los tres datasets para conservar únicamente los registros correspondientes a Bello, Itagüí y Envigado. Esto reduce el volumen de datos y garantiza coherencia con el alcance del proyecto.
- **Filtro 2 – Eliminación de columnas irrelevantes:** Se eliminaron las columnas denominadas “Unnamed” del dataset de Saber 11, dado que no aportan información para el estudio y presentan un alto porcentaje de valores faltantes.

7.2 Limpieza de datos

- **Limpieza 1 – Imputación de valores faltantes:** Para variables numéricas con valores faltantes se aplicará imputación por la media. Para variables categóricas se utilizará la moda.
- **Limpieza 2 – Eliminación de registros atípicos:** Se identificarán y eliminarán registros con valores erróneos (puntajes fuera del rango 0–100, número de accesos negativo) aplicando límites basados en percentiles o criterios de dominio.
- **Limpieza 3 – Normalización de nombres:** Se verificará la consistencia en el nombre de los municipios entre datasets (mayúsculas, tildes, abreviaciones) para garantizar un cruce correcto entre fuentes.

7.3 Transformaciones iniciales

- **Transformación 1 – Estandarización de accesos por población:** Se creará una variable que exprese el número de accesos de internet fijo por cada 1.000 habitantes en cada municipio, permitiendo comparar la penetración del servicio independientemente del tamaño poblacional.
- **Transformación 2 – Puntaje promedio municipal:** A partir de los resultados individuales del dataset Saber 11 se calculará el puntaje global promedio por municipio, sector educativo y periodo. Esta variable será la principal variable objetivo para el modelado.
- **Transformación 3 – Logaritmo de accesos:** Dado que la variable de accesos presenta una distribución muy sesgada, se aplicará una transformación logarítmica (Log10) para normalizar su distribución y mejorar la interpretabilidad en los modelos.
- **Transformación 4 – Consolidación temporal:** Los datasets de internet de 2021 y 2022–2023 serán unificados en un único dataframe con columna de periodo, permitiendo analizar la evolución temporal y cruzar con los periodos del dataset Saber 11.

Segunda entrega.

1. Filtros, limpieza y transformación inicial

En este apartado se describen los filtros, procesos de limpieza y transformaciones aplicadas sobre los datos en el clúster Apache Spark 3.5.8. A continuación se presenta el detalle de cada proceso.

1.1 Filtros aplicados

Se aplicaron dos filtros sobre los tres datasets:

```
Internet 2021: 399,848 filas | 12 columnas
Internet 2022-23: 1,369,085 filas | 12 columnas
[Stage 10:> (0 + 4) / 12]
Saber 11: 44,701 filas | 14 columnas
```

- **Filtro 1 – Selección por municipio:** Se filtraron los tres datasets para conservar únicamente los registros correspondientes a los municipios de Bello, Itagüí y Envigado. Para garantizar el cruce correcto entre fuentes, se implementó una función de normalización que convierte los nombres a mayúsculas y elimina tildes antes de aplicar el filtro, resolviendo las inconsistencias de capitalización entre datasets (por ejemplo, Itagüí, ITAGÜÍ e ITAGUI se tratan como el mismo valor). Este filtro redujo más del 95% de los registros en los datasets de internet, conservando únicamente el universo de análisis definido en la Entrega 1.
- **Filtro 2 – Eliminación de columnas Unnamed:** Se identificaron y eliminaron las columnas sin nombre (Unnamed) presentes en el dataset de Saber 11, las cuales son artefactos de exportación del archivo Excel original y no contienen información analítica relevante.

1.2 Limpieza de datos

Se realizaron tres procesos de limpieza:

- **Limpieza 1 – Separación de registros SC:** Los planteles con clasificación SC (Sin Clasificación, correspondiente a instituciones con menos de 10 evaluados) se separaron en un dataset aparte. Se conservan para análisis de cobertura pero se excluyen del cálculo de índices promedio para evitar sesgo en las agregaciones.

```
=== Internet Fijo 2021 ===
Sin valores faltantes relevantes.
```

```
=== Internet Fijo 2022-2023 ===
```

```
Sin valores faltantes relevantes.
```

```
=== Saber 11 (Clasif_planteles) ===
```

INDICE PLC	4 nulos (1.0%)
INDICE PMA	4 nulos (1.0%)
INDICE PSC	4 nulos (1.0%)
INDICE PCN	4 nulos (1.0%)
INDICE PIN	4 nulos (1.0%)
INDICE TOTAL	4 nulos (1.0%)

```
Registros SC (sin clasificacion): 16
```

```
Saber 11 con clasificacion valida: 402 filas
```

- **Limpieza 2 – Normalización de la variable de accesos:** La columna No DE ACCESOS fue convertida a tipo numérico (Double), eliminando separadores de miles inconsistentes. Se eliminaron los registros con valores negativos, correspondientes a errores de registro en la fuente original.
- **Limpieza 3 – Estandarización de nombres de municipio:** Se estandarizó la capitalización de la columna MUNICIPIO en los tres datasets a mayúsculas sin tilde, garantizando la consistencia necesaria para el cruce entre fuentes.

```
Accesos negativos o nulos eliminados.
```

```
Internet 2021 limpio:      6,722 filas
```

```
[Stage 169:=====
```

```
Internet 2022-23 limpio:  35,867 filas
```

```
Municipios estandarizados por dataset:
```

```
Internet 2021: ['BELLO', 'ENVIGADO', 'ITAGUI']
```


```
Internet 2022-23: ['BELLO', 'ENVIGADO', 'ITAGUI']
```

```
Saber 11: ['BELLO', 'ENVIGADO']
```


1.3 Transformaciones iniciales

Se aplicaron cuatro transformaciones sobre los datos:


- **T1 – Consolidación temporal:** Los datasets de internet fijo de 2021 y 2022–2023 fueron unidos en un único DataFrame mediante una operación union, generando una vista consolidada con columna de año que permite analizar la evolución temporal de la conectividad en el período 2021–2023.
- **T2 – Estandarización de accesos por población:** Se creó la variable ACCESOS_POR_MIL_HAB, que expresa el número de accesos de internet fijo por cada 1.000 habitantes en cada municipio, usando proyecciones poblacionales del DANE 2023 (Bello: 530.000 hab., Itagüí: 290.000 hab., Envigado: 250.000 hab.). Esta variable permite comparar la penetración del servicio independientemente del tamaño poblacional.




- **T3 – Transformación logarítmica de accesos:** Dado que la variable ACCESOS_TOTAL presenta una distribución fuertemente sesgada, se aplicó una transformación logarítmica en base 10 ($\text{LOG10_ACCESOS} = \log_{10}(\text{ACCESOS_TOTAL} + 1)$), normalizando su escala y mejorando su interpretabilidad en los modelos de aprendizaje de máquina.



- **T4 – Puntaje promedio Saber 11 por municipio y periodo:** A partir de los registros individuales de planteles, se calculó el índice promedio por municipio y año para las cinco áreas evaluadas (Lectura Crítica, Matemáticas, Ciencias Sociales, Ciencias Naturales e Inglés), así como el índice total. Esta agregación genera la variable objetivo principal para la fase de modelado.



El resultado de este proceso es un dataset integrado que cruza los indicadores de conectividad con los de rendimiento académico, con un registro por municipio y año.




2. Respuesta a preguntas de negocio planteadas

En este apartado se presentan los principales resultados obtenidos a partir del análisis de conectividad y desempeño académico en los municipios de Bello y Envigado durante el período 2021–2023. Las respuestas se construyen a partir de las tablas, transformaciones y visualizaciones generadas sobre el dataset integrado.

¿Cuál es el nivel de cobertura del servicio de internet fijo en los municipios del departamento de Antioquia durante el periodo 2021–2023?

El análisis de conectividad evidencia que Bello presenta la mayor cantidad de accesos absolutos de internet fijo durante el período analizado, superando los 500.000 accesos en 2021 y 2022. Sin embargo, al estandarizar la conectividad por población mediante la variable ‘ACCESOS_POR_MIL_HAB’, Envigado presenta consistentemente los niveles más altos de penetración del servicio.


Adicionalmente, se observa un crecimiento de conectividad entre 2021 y 2022 en ambos municipios, seguido de una disminución en 2023. Este comportamiento refleja cambios importantes en la dinámica de acceso y expansión de infraestructura tecnológica en el departamento.



¿Los municipios con mejor calidad de conectividad presentan mejores resultados en las pruebas ICFES 11?

Los resultados muestran una relación positiva entre conectividad y desempeño académico. Envigado presenta simultáneamente los mayores niveles de conectividad relativa y los mejores índices promedio en las pruebas Saber 11, con valores cercanos a 0.74 durante todo el período analizado.


No obstante, la relación observada no es completamente lineal. Bello presenta altos niveles de conectividad absoluta, pero resultados académicos inferiores respecto a Envigado. Esto sugiere que la conectividad representa un factor importante dentro del desempeño académico, aunque no constituye el único elemento explicativo.



¿Cuáles son los municipios de Antioquia con los mejores resultados en las pruebas Saber 11?

El índice promedio total calculado para cada municipio evidencia que Envigado mantiene consistentemente los mejores resultados académicos durante el período 2021–2023. Sus índices promedio se mantienen cercanos a 0.74, mientras que Bello registra valores promedio cercanos a 0.66.

La diferencia observada refleja una brecha académica importante entre municipios, posiblemente asociada a diferencias socioeconómicas, calidad educativa y acceso a recursos tecnológicos.



¿Qué municipios de Antioquia deberían ser priorizados en futuras estrategias de mejoramiento de conectividad?

Los resultados sugieren que Bello podría requerir una mayor priorización en futuras estrategias de fortalecimiento educativo y digital. Aunque presenta altos niveles de conectividad absoluta, sus resultados académicos continúan siendo inferiores frente a Envigado.


Esto indica que futuras estrategias no deberían enfocarse únicamente en ampliar infraestructura tecnológica, sino también en fortalecer factores asociados a calidad educativa y reducción de brechas sociales.

(INSERTAR TABLA COMPARATIVA ENTRE CONECTIVIDAD Y RENDIMIENTO)

¿Qué patrones observados entre 2021 y 2023 permiten estimar tendencias futuras sobre la relación entre conectividad y desempeño académico en los municipios de Antioquia?

El análisis temporal muestra que los municipios con mayor penetración relativa de internet también presentan mejores niveles de desempeño académico. Envigado constituye el principal ejemplo de este comportamiento durante los tres años analizados.


Además, se observa que el crecimiento de conectividad no genera automáticamente mejoras proporcionales en el rendimiento académico. Esto indica que la relación entre ambas variables es positiva, pero depende también de factores adicionales relacionados con contexto educativo y condiciones socioeconómicas.



¿Es posible proyectar qué municipios podrían mejorar su desempeño en las pruebas Saber 11 a partir de un aumento en el acceso o calidad del servicio de internet fijo?

Los modelos aplicados muestran que existe una asociación positiva entre conectividad y desempeño académico. Los resultados de la Regresión Lineal presentan un alto ajuste sobre los datos analizados, evidenciando que variables relacionadas con conectividad pueden contribuir a explicar parcialmente el comportamiento del índice promedio Saber 11.


Sin embargo, debido al tamaño reducido del dataset integrado, estas proyecciones deben interpretarse como una aproximación exploratoria y no como predicciones definitivas.



¿Qué municipios presentan buenos resultados en Saber 11 con baja conectividad o malos resultados con alta conectividad?

El análisis evidencia que Bello presenta niveles altos de conectividad absoluta, pero resultados académicos inferiores frente a Envigado. Este comportamiento demuestra que una mayor disponibilidad de accesos a internet no garantiza automáticamente mejores resultados académicos.

Por otra parte, Envigado combina altos niveles de conectividad relativa con los mejores resultados académicos del conjunto analizado, evidenciando un comportamiento más equilibrado entre infraestructura tecnológica y desempeño educativo.



¿Es posible agrupar o categorizar los municipios de Antioquia según niveles de conectividad y desempeño académico para identificar relaciones?

La aplicación del modelo K-Means permitió identificar agrupamientos entre municipios según sus características de conectividad y desempeño académico. El modelo logró separar observaciones con comportamientos similares, diferenciando municipios con mejores niveles de conectividad y mayores índices Saber 11 frente a municipios con resultados inferiores.

Adicionalmente, el valor obtenido en la métrica Silhouette Score evidencia una separación adecuada entre los grupos identificados por el modelo, permitiendo reconocer patrones diferenciados dentro de los datos analizados.

```
=====
MODELO NO SUPERVISADO - KMEANS
=====
[Stage 680:=====>
```

Clusters encontrados:

	Municipio	Año	Indice Saber 11	Cluster
0	BELLO	2021.0	0.6600	0
1	BELLO	2022.0	0.6620	0
2	BELLO	2023.0	0.6646	0
3	ENVIGADO	2021.0	0.7345	1
4	ENVIGADO	2022.0	0.7363	1
5	ENVIGADO	2023.0	0.7443	0

Evaluacion del modelo:

	Metrica	Valor
0	Silhouette Score	0.874336

Centroides de los clusters:

	LOG10_ACCESOS	ACCESOS_POR_MIL_HAB	INDICE_PROM_TOTAL
0	5.628025	970.9675	0.682725
1	5.519350	1323.1350	0.735400

3. Selección de técnicas de aprendizaje de máquina

Con el fin de profundizar el análisis de la relación entre conectividad y desempeño académico, se seleccionaron dos técnicas de aprendizaje de máquina: una técnica supervisada y una técnica no supervisada. La selección de estas técnicas se realizó teniendo en cuenta el objetivo principal del proyecto, orientado a analizar cómo los niveles de acceso a internet fijo pueden relacionarse con los resultados obtenidos en las pruebas Saber 11 en los municipios de Bello, Itagüí y Envigado.

3.1 Regresión Lineal

Como técnica de aprendizaje supervisado se seleccionó la Regresión Lineal. Esta técnica permite predecir una variable numérica continua a partir de un conjunto de variables explicativas. En este caso, la variable objetivo corresponde al índice promedio total de las pruebas Saber 11 (INDICE_PROM_TOTAL), mientras que las variables predictoras corresponden a indicadores de conectividad construidos durante las fases anteriores del proyecto, tales como LOG10_ACCESOS, ACCESOS_POR_MIL_HAB y el período analizado.

La selección de este modelo se justifica debido a que el proyecto busca identificar si existe una relación entre la conectividad y el desempeño académico en los municipios seleccionados. La Regresión Lineal permite analizar tendencias entre variables y estimar cómo cambios en los indicadores de conectividad pueden relacionarse con variaciones en los índices académicos. Además, se trata de un modelo interpretable y adecuado para el tipo de variables numéricas presentes en el dataset integrado.

3.2 K-Means

Como técnica de aprendizaje no supervisado se seleccionó el algoritmo K-Means. Esta técnica permite agrupar observaciones con características similares sin utilizar una variable objetivo previamente definida. La implementación de K-Means se relaciona directamente con una de las preguntas de negocio planteadas inicialmente, enfocada en identificar posibles agrupamientos de municipios según sus niveles de conectividad y desempeño académico.

Para el proceso de agrupamiento se utilizaron variables relacionadas con intensidad de conectividad y resultados educativos, tales como LOG10_ACCESOS, ACCESOS_POR_MIL_HAB e INDICE_PROM_TOTAL. A partir de estas variables, el modelo permite identificar patrones entre municipios con comportamientos similares, diferenciando posibles grupos con altos niveles de conectividad y rendimiento académico frente a municipios con menores indicadores.

La selección de K-Means se justifica debido a que permite explorar la estructura interna de los datos y detectar agrupamientos sin necesidad de definir previamente categorías o

etiquetas. Esto resulta útil para identificar patrones territoriales y posibles diferencias entre municipios según sus condiciones de conectividad y desempeño educativo.

=====

MODELO NO SUPERVISADO – KMEANS

=====

[Stage 680:=====>

Clusters encontrados:

	Municipio	Año	Indice Saber 11	Cluster
0	BELLO	2021.0	0.6600	0
1	BELLO	2022.0	0.6620	0
2	BELLO	2023.0	0.6646	0
3	ENVIGADO	2021.0	0.7345	1
4	ENVIGADO	2022.0	0.7363	1
5	ENVIGADO	2023.0	0.7443	0

Evaluacion del modelo:

	Metrica	Valor
0	Silhouette Score	0.874336

Centroides de los clusters:

	LOG10_ACCESOS	ACCESOS_POR_MIL_HAB	INDICE_PROM_TOTAL
0	5.628025	970.9675	0.682725
1	5.519350	1323.1350	0.735400

4. Preparación de los datos para modelado.

Para la etapa de modelado se construyó un dataframe consolidado a partir de las variables consideradas más significativas provenientes de los conjuntos de datos de acceso a internet y de resultados de las pruebas Saber. El objetivo de esta integración fue disponer de un conjunto de datos unificado que permitiera analizar posibles relaciones entre la conectividad y el desempeño académico de los municipios.

El dataframe final quedó conformado por las siguientes variables:

- ‘AÑO’
- ‘MUNICIPIO’
- ‘ACCESOS_TOTAL’
- ‘POBLACION’
- ‘ACCESOS_POR_MIL_HAB’
- ‘LOG10_ACCESOS’
- ‘INDICE_PROM_TOTAL’
- ‘INDICE_PROM_LC’
- ‘INDICE_PROM_MAT’
- ‘INDICE_PROM_SOC’
- ‘INDICE_PROM_CN’
- ‘INDICE_PROM_IN’
- ‘NUM_PLANTELES’

Durante el proceso de selección de variables se identificó la existencia de algunas columnas con alta correlación entre sí, como ocurre entre ‘ACCESOS_TOTAL’ y ‘LOG10_ACCESOS’. Sin embargo, se decidió conservar ambas variables debido a que representan perspectivas diferentes de la misma información: mientras ‘ACCESOS_TOTAL’ mantiene los valores originales y su interpretación

directa, 'LOG10_ACCESOS' permite trabajar con una escala comprimida que reduce el impacto de valores extremos y facilita el comportamiento de ciertos modelos de aprendizaje automático.

En cuanto al tratamiento de variables numéricas, no se aplicó una normalización clásica basada en escalamiento Min-Max o estandarización Z-score. En su lugar, se optó por realizar una transformación logarítmica sobre la variable de accesos totales, mediante el cálculo de:

$$\log_{10}(ACCESOS_TOTAL + 1)$$

Esta transformación permitió reducir la asimetría de la distribución de datos y disminuir el efecto de valores atípicos asociados a municipios con cantidades de accesos significativamente superiores al promedio.

=====				
MODELO SUPERVISADO - REGRESION LINEAL				
=====				
[Stage 554:=====>				
Predicciones del modelo:				
	Municipio	Año	Indice Real	Prediccion
0	BELLO	2021.0	0.6600	0.6595
1	BELLO	2022.0	0.6620	0.6593
2	BELLO	2023.0	0.6646	0.6680
3	ENVIGADO	2021.0	0.7345	0.7358
4	ENVIGADO	2022.0	0.7363	0.7375
5	ENVIGADO	2023.0	0.7443	0.7416
[Stage 582:=====>				
Metricas del modelo:				
	Metrica	Valor		
0	RMSE	0.002230		
1	R2	0.996595		

5. Reporte de Calidad de Datos y Preprocesamiento

Para garantizar la validez, consistencia y robustez analítica del modelo no supervisado de agrupación (*K-Means*), se implementó una fase rigurosa de auditoría y limpieza sobre los conjuntos de datos: *Internet_Fijo_Accesos_por_tecnologia_y_segmento_2021.csv* y *Cuadros_salida_saber_11_2023.csv*. A continuación, se detallan los hallazgos y los protocolos técnicos aplicados.

5.1. Identificación de Valores Faltantes (Fase de Diagnóstico)

El diagnóstico inicial se ejecutó mediante algoritmos de vectorización en Python (*Pandas*), utilizando la función matricial `.isnull().sum()`. Esta técnica escanea cada registro indexado en busca de valores nulos o estructuras *NaN* (*Not a Number*).

- **Dataset de Internet Fijo (2021):** El diagnóstico confirmó una integridad estructural del 100% en las variables críticas de conectividad. No se registraron valores faltantes significativos, lo que valida la consistencia de la recolección de datos por parte de la entidad fuente.

- **Dataset de Pruebas Saber 11 (2023):** Se identificó una anomalía sistemática caracterizada por la presencia de múltiples columnas con prefijos Unnamed:. Estas columnas presentaban una tasa de vacíos cercana al 100%, originadas comúnmente por errores de desalineación en los delimitadores del archivo CSV original o remanentes de índices de exportaciones previas.

5.2. Análisis de la Calidad de los Datos

La calidad de los datos se evaluó bajo tres criterios fundamentales: completitud, unicidad y conformidad de tipo.

1. **Completitud:** Las variables objetivo para el negocio (municipios, puntajes promedio y accesos a internet) contaban con una representatividad estadística alta. Las ausencias detectadas se concentraron exclusivamente en metadatos irrelevantes.
2. **Conformidad de Tipo:** Se identificó que, debido a caracteres especiales o fallas de codificación en la lectura inicial, algunas variables cuantitativas corrían el riesgo de ser interpretadas como cadenas de texto (strings). Esto requirió un proceso de coerción de tipos, indispensable para el algoritmo K-Means, el cual opera estrictamente sobre distancias euclidianas en espacios numéricos continuos.

5.3. Protocolo y Técnicas de Tratamiento de Datos Aplicadas

Con el fin de mitigar sesgos y evitar distorsiones en el cálculo de los centroides del modelo de Machine Learning, se ejecutó el siguiente protocolo automatizado de limpieza

A. Filtrado y Supresión de Columnas Irrelevantes

Para optimizar el uso de memoria y eliminar ruido analítico, se aplicó un filtro basado en expresiones regulares (Regex):

```
$$\neg \text{columnas que contengan } \text{"^Unnamed"}$$
```

A través del método `.loc[:, ~df.columns.str.contains('^Unnamed')]`, se removieron de forma masiva todas las columnas espurias, conservando únicamente los atributos válidos para el estudio.

B. Imputación Estadística de Valores Faltantes

En caso de detectar registros nulos aislados en las variables fundamentales, se diseñó un protocolo de imputación diferenciado según la naturaleza del dato, evitando la pérdida masiva de filas:

- **Variables Numéricas (Ej. INDICE_PROM_TOTAL):** Se utilizó una técnica de imputación por tendencia central (la media) mediante la función `.fillna(media)`. Esto preserva el promedio global del conjunto sin alterar drásticamente la varianza de la muestra.
- **Variables Categóricas (Ej. MUNICIPIO):** Se implementó una imputación por el método de la moda (el valor más frecuente), garantizando la coherencia textual del dataset.

C. Coerción de Tipos de Datos y Control de Ruido

Las variables clave seleccionadas para el agrupamiento (`LOG10_ACCESOS`, `ACCESOS_POR_MIL_HAB` e `INDICE_PROM_TOTAL`) fueron procesadas con la función `pd.to_numeric(..., errors='coerce')`. Esta instrucción fuerza la transformación de los datos a tipo flotante (`float64`). Cualquier celda que contenga un carácter no numérico o corrupto es transformada inmediatamente en `NaN` y eliminada en el paso posterior mediante `.dropna()`, blindando al modelo contra errores en tiempo de ejecución.

D. Eliminación de Registros Duplicados

La presencia de filas idénticas puede generar un peso artificial sobre ciertas coordenadas espaciales, atrayendo erróneamente los centros de los clústeres. Se aplicó la función `.drop_duplicates(inplace=True)` en ambas bases de datos para garantizar el principio de unicidad, asegurando que cada observación de un municipio y su respectivo año represente un único punto geométrico real en el espacio de análisis.

6. Aplicación de métricas y evaluación de modelos

Con el fin de evaluar el desempeño de las técnicas de aprendizaje de máquina implementadas, se aplicaron métricas acordes al tipo de problema abordado. Para el modelo supervisado de Regresión Lineal se utilizaron métricas de error y ajuste del modelo, mientras que para el modelo no supervisado K-Means se utilizó una métrica orientada a medir la calidad de los agrupamientos generados.

Adicionalmente, se realizaron pruebas utilizando diferentes parámetros para cada modelo con el objetivo de comparar configuraciones y analizar el comportamiento de las técnicas implementadas sobre el dataset integrado.

6.1 Evaluación del modelo de Regresión Lineal

Para evaluar el desempeño del modelo supervisado se utilizaron las métricas RMSE y R^2 . La métrica RMSE (Root Mean Squared Error) permite medir el error promedio entre los valores reales y las predicciones generadas por el modelo. Esta métrica resulta adecuada debido a que el problema trabajado corresponde a una predicción numérica continua relacionada con el índice promedio de las pruebas Saber 11.

Por otra parte, se utilizó la métrica R^2 debido a que permite medir el nivel de ajuste de la regresión sobre los datos analizados. Valores cercanos a 1 indican que el modelo logra explicar gran parte de la variabilidad presente en la variable objetivo.

Con el fin de comparar resultados, se realizaron pruebas modificando los parámetros `maxIter` y `regParam`. El parámetro `maxIter` controla el número máximo de iteraciones utilizadas durante el entrenamiento, mientras que `regParam` corresponde al nivel de regularización aplicado sobre el modelo.

Los resultados obtenidos fueron los siguientes:

=====

PRUEBAS REGRESION LINEAL

=====

	MaxIter	RegParam	RMSE	R2
0	10	0.0	0.002230	0.996595
1	50	0.1	0.025183	0.565983
2	100	0.5	0.034615	0.179985

Los resultados evidencian que la mejor configuración corresponde al modelo con $\text{maxIter} = 10$ y $\text{regParam} = 0.0$, ya que presenta el menor valor de RMSE y el mayor valor de R^2 . Esto indica un alto nivel de ajuste entre las predicciones generadas y los valores reales observados en el dataset.

Adicionalmente, se observa que al aumentar el parámetro de regularización (regParam), el desempeño del modelo disminuye considerablemente. Esto se evidencia en el aumento progresivo del RMSE y la reducción del valor de R^2 en las demás pruebas realizadas.

Sin embargo, debido al tamaño reducido del dataset integrado, estos resultados deben interpretarse como una aproximación exploratoria y no como un modelo predictivo generalizable.

6.2 Evaluación del modelo K-Means

Para evaluar el desempeño del modelo K-Means se utilizó la métrica Silhouette Score. Esta métrica permite medir la calidad de los agrupamientos generados por el algoritmo, evaluando qué tan similares son las observaciones dentro de cada cluster y qué tan diferentes son respecto a otros grupos.

La utilización de esta métrica resulta adecuada debido a que el problema abordado corresponde a un proceso de agrupamiento no supervisado, donde no existe una variable objetivo previamente definida. El Silhouette Score permite entonces identificar qué configuración genera clusters más consistentes y mejor separados.

Con el fin de comparar resultados, se realizaron pruebas utilizando diferentes valores de K, correspondientes al número de clusters generados por el modelo.

Los resultados obtenidos fueron los siguientes:

```
=====
PRUEBAS KMEANS
=====
```

	K	Silhouette Score
0	2	0.874336
1	3	0.763099
2	4	0.452817

Los resultados muestran que la mejor configuración corresponde a $K = 2$, debido a que presenta el mayor valor de Silhouette Score. Esto indica que los grupos generados por el modelo presentan una separación más clara y consistente respecto a las demás configuraciones evaluadas.

Por otra parte, al incrementar el número de clusters, la calidad de los agrupamientos disminuye progresivamente. Esto se evidencia en la reducción del Silhouette Score para $K = 3$ y $K = 4$.

Este comportamiento resulta coherente considerando que el dataset utilizado contiene un número reducido de observaciones, por lo que una cantidad elevada de clusters genera agrupamientos menos estables y menos diferenciados.

7. Modelo de aprendizaje profundo (Bono)

Como parte del componente adicional del proyecto, se implementó un modelo de aprendizaje profundo utilizando una red neuronal artificial mediante `MultilayerPerceptronClassifier` de Spark MLlib. El objetivo del modelo consistió en analizar si las variables relacionadas con conectividad permitían clasificar los municipios según su nivel de desempeño académico en las pruebas Saber 11.

Debido a que las redes neuronales implementadas en Spark MLlib trabajan principalmente con problemas de clasificación, previamente se construyó una variable categórica denominada `CLASE_RENDIMIENTO`. Esta variable fue creada a partir del índice promedio total de las pruebas Saber 11 (`INDICE_PROM_TOTAL`), tomando como referencia el promedio general del dataset. Los registros con valores iguales o superiores al promedio fueron clasificados como alto desempeño (1), mientras que los registros inferiores al promedio fueron clasificados como bajo desempeño (0).

Para el entrenamiento del modelo se utilizaron variables asociadas a conectividad y temporalidad, específicamente `LOG10_ACCESOS`, `ACCESOS_POR_MIL_HAB` y `AÑO`.

Posteriormente, estas variables fueron ensambladas mediante VectorAssembler para construir el vector de características utilizado por la red neuronal.

La arquitectura del modelo fue configurada utilizando múltiples capas neuronales (layers = [3, 5, 4, 2]), incluyendo capas ocultas intermedias orientadas a identificar patrones entre las variables de entrada y la clasificación final del rendimiento académico.

Una vez entrenado el modelo, se obtuvieron los siguientes resultados:

=====					
MODELO DE RED NEURONAL					
=====					
	Municipio	Año	Indice	Clase Real	Prediccion
0	BELLO	2021.0	0.6600	0	1.0
1	BELLO	2022.0	0.6620	0	1.0
2	BELLO	2023.0	0.6646	0	1.0
3	ENVIGADO	2021.0	0.7345	1	1.0
4	ENVIGADO	2022.0	0.7363	1	1.0
5	ENVIGADO	2023.0	0.7443	1	1.0

Para evaluar el desempeño de la red neuronal se utilizó la métrica Accuracy, debido a que corresponde a un problema de clasificación supervisada. Esta métrica permite medir el porcentaje de predicciones correctas realizadas por el modelo respecto a las clases reales observadas en los datos.

El modelo obtuvo un Accuracy de 0.5, indicando que aproximadamente el 50% de las observaciones fueron clasificadas correctamente. Los resultados muestran que la red neuronal tendió a clasificar todos los registros dentro de la misma categoría, generando errores principalmente en los municipios correspondientes a Bello.

Este comportamiento evidencia limitaciones importantes en la capacidad predictiva del modelo sobre el dataset trabajado. Sin embargo, este resultado era esperable debido al tamaño reducido del conjunto de datos utilizado durante el entrenamiento. Las redes neuronales suelen requerir grandes volúmenes de información para identificar patrones complejos y generar modelos robustos.

A pesar de estas limitaciones, la implementación permitió demostrar la aplicación de técnicas de aprendizaje profundo sobre Apache Spark MLlib, complementando los análisis realizados previamente mediante modelos supervisados y no supervisados tradicionales.

Metricas del modelo:



	Metrica	Valor
0	Accuracy	0.5